

Université Alger 3 — Master Économie Quantitative

Module : Applications au Deep Learning

Travaux Pratiques— Régression Linéaire avec TensorFlow/Keras

Nom : Issiakhem

Prénom : Yasmine

مدخلات :

```
# =====
```

```
# TP COMPLET : REGRESSION LINEAIRE AVEC KERAS
```

```
# =====
```

```
# =====
```

```
import numpy as np
```

```
import tensorflow as tf
```

```
from tensorflow import keras
```

```
import matplotlib.pyplot as plt
```

```
print("="*70)
```

```
print("TP COMPLET : REGRESSION LINEAIRE AVEC KERAS")
```

```
print("="*70)
```

```
# =====
```

```
# التمرين الأول - التعامل مع البيئة والتحقق منها
```

```
# =====
```

```
print("\n" + "="*70)
```

```
print("التمرين الأول - التعامل مع البيئة والتحقق منها")
```

```
print("="*70)
```

```
print("\n:وأجب عن الأسئلة التالية Google Colab انطلاقاً من البرنامج المُرفق، نفذ في n")
```

```

print("\n• لديك؟ Google Colab المُنْبَت في بيئة TensorFlow ما إصدار")
print(f"الإجابة TensorFlow version {tf.__version__}")

print("\n• المرتبط بهذه التثبيت؟ Keras ما إصدار")
print(f"الإجابة Keras version {keras.__version__}")

print("\n• متاحة؟ كيف استنتجت ذلك من الكود؟ (GPU) هل وحدة معالجة الرسومات")
gpu_devices = tf.config.list_physical_devices('GPU')
if gpu_devices:
    print(f"متاح GPU الإجابة: نعم، {gpu_devices[0]}")
else:
    print("غير متاح GPU الإجابة: لا،")
print("tf.config.list_physical_devices('GPU') الطريقة: باستخدام")
print("موجود GPU → ، إذا كانت تحتوي على عناصر GPU إذا كانت القائمة فارغة → لا يوجد")
print("\n• عند تدريب نموذج بسيط كهذا. ما تأثيره على وقت الحساب؟ GPU اشرح في بضعة أسطر ما يعنيه غياب")
print("الإجابة:")

```

- غياب GPU له تأثير ضئيل جداً على نموذج بسيط كهذا
- العمليات الحسابية للانحدار الخطي بسيطة ولا تتطلب معالجة متوازية قوية
- الفرق في وقت الحساب بين CPU و GPU هو بضع أجزاء من الثانية
- GPU - يصبح ضرورياً للنماذج العميقة المعقدة (CNNs, RNNs, Transformers)
- لذلك، لتدريب هذا النموذج، CPU كافٍ تماماً

```

)
# =====
التمرين الثاني - التحليل النقدي لنتيجة التدريب
# =====

```

```

print("\n" + "="*70)

```

```
print("التمرين الثاني - التحليل النقدي لنتيجة التدريب")
```

```
print("=*70)
```

```
print("\n2.317 بعد تنفيذ البرنامج الأولي، حصلت على قيمة خسارة نهائية تساوي
```

```
print("\n• ما المقصود بـ MSE الرياضية صيغته الرياضية MSE ما المقصود بـ
```

```
print("الإجابة:
```

$$MSE = (1/n) * \sum (y_i - \hat{y}_i)^2$$

حيث:

n : - عدد العينات

y_i : - القيمة الحقيقية

y_i : - القيمة المتوقعة

MSE : - متوسط مربعات الأخطاء

```
print("\n
```

```
print("\n• البالغة 2.317 مرتفعة بشكل غير MSE في سياق بيانات مُطَبَّعة بين 0 و1، وضَّح لماذا تعتبر قيمة طبيعية")
```

```
print("الإجابة:
```

- البيانات مطبوعة (normalisée) بين 0 و 1

- لأي عينة، الفرق بين القيمة الحقيقية والمتوقعة ≥ 1

- مربع هذا الفرق ≥ 1

- متوسط هذه المربعات ≥ 1

- لذلك فإن $MSE > 1$ مستحيل في الظروف العادية

- $MSE = 2.317$ - تعني أن التوقعات خارجة عن النطاق [0,1] (سلبية أو >1)

```
print("\n
```

```
print("\n• بالنسبة لنموذج مُدرَّب جيداً على هذه البيانات؟ MSE ما القيمة التي تعتبرها مقبولة لـ
```

```
print("الإجابة:
```

- قيمة MSE: مقبولة < 0.01

- قيمة MSE: جيدة جداً < 0.001

- قيمة MSE: ممتازة < 0.0001 :

- للنموذج الخطي المثالي $MSE = 0$

```
"""
```

```
print("\n• تعديل على البرنامج")
```

```
print(""" الإجابة (الفرضيات):
```

1. معدل التعلم (learning rate) غير مناسب:

- كبير جداً → النموذج يتباعد ولا يتقارب

- صغير جداً → النموذج يتعلم ببطء شديد

2. عدد الحَقَب (epochs) غير كافٍ:

- الحقبة الواحدة لا تسمح بالنزول إلى المطلوب

3. التهيئة الأولية للأوزان سيئة

4. عدم تطبيع البيانات بشكل صحيح

```
""")
```

```
# =====
```

```
# التمرين الثالث - استخراج معادلة النموذج
```

```
# =====
```

```
print("\n" + "="*70)
```

```
print("التمرين الثالث - استخراج معادلة النموذج")
```

```
print("="*70)
```

```
# Donnees
```

```
surface = np.array([50, 60, 80, 100, 120], dtype=float)
```

```
prix = np.array([150, 180, 240, 300, 360], dtype=float)
```

```
print("\nالبيانات:")
```

```
for i in range(len(surface)):
```

```
    print(f" المساحة : {surface[i]:3.0f} m2 → السعر : {prix[i]:3.0f} k€")
```

```
# Normalisation
```

```
s_min, s_max = surface.min(), surface.max()
```

```
p_min, p_max = prix.min(), prix.max()
```

```
s_norm = (surface - s_min) / (s_max - s_min)
```

```

p_norm = (prix - p_min) / (p_max - p_min)

print("\n(بعد التطبيع (قيم بين 0 و 1)
for i in range(len(surface)):
    print(f" surface_norm[{i}] = {s_norm[i]:.4f} , prix_norm[{i}] = {p_norm[i]:.4f}")

# Modele non entraine pour demonstration

model_temp = keras.Sequential([keras.layers.Dense(1, input_shape=[1])])
model_temp.compile(optimizer='sgd', loss='mse')
model_temp.fit(s_norm, p_norm, epochs=1, verbose=0)

print("\n(من النموذج المدرب (b) والانحياز (w) لاستخراج الأوزان (model.get_weights() استخدم الدالة
weights_temp = model_temp.get_weights()
w_temp = weights_temp[0][0, 0]
b_temp = weights_temp[1][0]
print(f" (الوزن) w = {w_temp:.6f} (الإجابة
print(f" (الانحياز) b = {b_temp:.6f}

print("\n(اعرض معادلة النموذج في الحجم المطبّع على الشكل
print(f" (الإجابة: prix_norm = {w_temp:.6f} × surface_norm + {b_temp:.6f}

print("\n(فصل (k€ ، السعر بـ m² المساحة بـ) أجر عملية إلغاء التطبيع واعرض المعادلة في الحجم الحقيقي
(خطوات الحساب المستخدمة

# Denormalisation

A_temp = w_temp * (p_max - p_min) / (s_max - s_min)
C_temp = p_min + b_temp * (p_max - p_min) - A_temp * s_min

print(f" (الإجابة:

```

الخطوة 1: حساب الميل A في المعادلة الحقيقية

$$A = w \times (P_{\max} - P_{\min}) / (S_{\max} - S_{\min})$$

$$A = \{w_temp:.6f\} \times (\{p_max\} - \{p_min\}) / (\{s_max\} - \{s_min\})$$

$$A = \{A_temp:.4f\}$$

الخطوة 2: حساب التقاطع C

$$C = P_{\min} + b \times (P_{\max} - P_{\min}) - A \times S_{\min}$$

$$C = \{p_min\} + \{b_temp:.6f\} \times (\{p_max\} - \{p_min\}) - \{A_temp:.4f\} \times \{s_min\}$$

$$C = \{C_temp:.2f\}$$

$$(k\text{€}) = \{A_temp:.4f\} \times \text{المساحة (m}^2\text{)} + \{C_temp:.2f\}$$

""")

print("\n• 100 مساحة يدوياً المتوقع السعر من نتيجتك بحساب السعر المتوقع لمساحة 100 m².")

test_100 = A_temp * 100 + C_temp

print(f" 100 المساحة المتوقع السعر المتوقع: الإجابة: m² = {A_temp:.4f} × 100 + {C_temp:.2f} = {test_100:.2f} k€")

print(f" 300 السعر الحقيقي المتوقع = k€")

=====

التمرين الرابع - تشخيص مشكلة التقارب

=====

print("\n" + "="*70)

print("التمرين الرابع - تشخيص مشكلة التقارب")

print("="*70)

Predictions du mauvais modele

predictions_bad = model_temp.predict(s_norm, verbose=0).flatten()

print("\n1 عند تنفيذ البرنامج المعدل، لاحظت توقعات سلبية رغم أن الأسعار المطبّعة تقع بين 0 و 1")

print("\n• حلّل النتائج التالية و اشرح ما تدل عليه")

print(" : التوقعات [-0.1458, -0.2918, -0.3892, -0.4866, -0.6326]")

print(" : القيم الحقيقية [0.3333, 0.5333, 0.6667, 0.8000, 1.0000]")

print(""" التحليل:

- جميع التوقعات سالبة بينما القيم الحقيقية موجبة
- كلما زادت المساحة، أصبحت التوقعات أكثر سلبية (علاقة عكسية)
- هذا يدل على أن النموذج لم يتعلم أي شيء
- النموذج يعطي وزناً سالباً للمساحة
- سبب المشكلة: عدد الحَقَب غير كافٍ ومعدل التعلم غير مناسب

""")

print("\n• هذا الخلل في البرنامج الأولي المسؤولين عن هذا الخلل")

print(""" الإجابة:

- 1. epochs (عدد الحَقَب): القيمة الافتراضية كانت 1 أو غير محددة
 - 2. learning_rate (معدل التعلم): القيمة الافتراضية 0.01 قد تكون غير مناسبة
- هذان المعاملان هما المسؤولان الرئيسيان عن فشل التقارب

""")

print("\n• وسرعة تقارب الشبكة العصبية (learning rate) وضّح العلاقة بين معدل التعلم

print(""" الإجابة:

- معدل تعلم صغير جداً: التقارب بطيء جداً، يحتاج إلى حقبة كثيرة جداً
- معدل تعلم مناسب: تقارب سريع ومستقر نحو الحل الأمثل
- معدل تعلم كبير جداً: النموذج يتباعد (diverge) ، قد تصل الخسارة إلى ما لانهاية
- في حالتنا: 0.1 يعتبر مناسباً للبيانات المطبوعة بين 0 و 1
- العلاقة LR: الأمثل = 0.01 إلى 0.1 للبيانات المطبوعة

""")

print("\n• ما المقصود بتقارب النموذج؟ كيف نتيج لك دالة الخسارة اكتشافه؟")

print(""" الإجابة:

تقارب النموذج: هو الوصول إلى حالة تستقر فيها دالة الخسارة عند قيمة دنيا ولا تنقص أكثر.

اكتشاف التقارب عبر دالة الخسارة:

- خلال التدريب، نراقب قيمة MSE في كل حقبة
- عندما تبقى MSE ثابتة أو تتغير بقيم صغيرة جداً ($< 1e-6$)

- ولم تنخفض بشكل ملحوظ لعدة حقبة متتالية
- هذا يعني أن النموذج قد تقارب
- في مثالنا MSE: تتناقص بشكل كبير ثم تستقر قرب الصفر

""")

=====

التمرين الخامس - تصحيح البرنامج وتحسينه

=====

print("\n" + "="*70)

print("التمرين الخامس - تصحيح البرنامج وتحسينه")

print("="*70)

print("\nبناءً على تشخيصك، اقترح نسخة معدلة من البرنامج ونفذها")

print("\n• عدّل معدل التعلم بالانتقال من القيمة الافتراضية إلى 0.1. برّر هذا الاختيار")

print("""التبرير:

0.1 - هو معدل تعلم متوسط للبيانات المطبوعة بين 0 و 1

- ليس كبيراً جداً ليسبب تباعداً، وليس صغيراً جداً ليسبب بطئاً

- يسمح بتقارب سريع في غضون 100-200 حقبة

- جربناه وكانت النتائج ممتازة (MSE) تصل إلى 0)

""")

print("\n• إلى 500. وضّح لماذا يُفضي عدد أكبر من الحَقَب إلى تقارب أفضل (epochs) ارفع عدد الحَقَب

print("""التفسير:

- كل حقبة تعني تمريرة كاملة على جميع البيانات

- مع عدد قليل من الحَقَب، النموذج لا يصل إلى الحل الأمثل

100-500 - حقبة كافية لنماذج بسيطة

500 - حقبة تضمن وصول النزول المتدرج (Gradient Descent) إلى أدنى نقطة

- مع 500 حقبة، نلاحظ أن MSE تصل إلى 0.000000

""")

Modele corrige

```
model_good = keras.Sequential([keras.layers.Dense(1, input_shape=[1])])
model_good.compile(optimizer=keras.optimizers.SGD(learning_rate=0.1), loss='mse')
class ProgressCallback(tf.keras.callbacks.Callback):
    def on_epoch_end(self, epoch, logs=None):
        if (epoch + 1) % 100 == 0:
            print(f"الحقبة {epoch+1:4d} : قيمة الخسارة (MSE) = {logs['loss']:.10f}")
print("\n• أضف عرضاً لقيمة الخسارة كل 100 حقبة لتصور تقدم التعلم")
print("...جارٍ التدريب")
history = model_good.fit(s_norm, p_norm, epochs=500, verbose=0,
callbacks=[ProgressCallback()])
print("\n• علق على تطور الخسارة التي تلاحظها بين الحقبة 1 والحقبة 500")
print(f"التعليق: ")
```

- الحقبة 1: الخسارة = {history.history['loss'][0]:.8f} مرتفعة نسبياً)
- الحقبة 100: الخسارة = {history.history['loss'][99]:.8f} انخفضت بشكل كبير)
- الحقبة 200: الخسارة = {history.history['loss'][199]:.8f} شبه منعدمة)
- الحقبة 500: الخسارة = {history.history['loss'][-1]:.12f} شبه صفرية)

الملاحظة: الخسارة تتناقص بسرعة في أول 100 حقبة ثم تستقر قرب الصفر.

هذا يدل على أن النموذج تعلم العلاقة الخطية تماماً.

```
""")
```

```
# =====
```

```
# التمرين السادس - تفسير النتائج النهائية
```

```
# =====
```

```
print("\n" + "="*70)
```

```
print("التمرين السادس - تفسير النتائج النهائية")
```

```
print("="*70)
```

Extraction des poids finaux

```
weights_final = model_good.get_weights()
```

```
w_final = weights_final[0][0, 0]
```

```
b_final = weights_final[1][0]
```

```
A_final = w_final * (p_max - p_min) / (s_max - s_min)
```

```
C_final = p_min + b_final * (p_max - p_min) - A_final * s_min
```

```
print(f"\nالمساحة (m²) = {A_final:.4f} × المساحة (k€) = {C_final:.2f} +  
السعر (m²) = {C_final:.2f}")
```

```
print("\n• التفسير: هذه النتيجة متوقعة رياضياً بالنظر إلى بنية البيانات المُقدّمة")
```

```
print("التفسير:")
```

- البيانات المعطاة تتبع علاقة خطية تامة: السعر = 3 × المساحة

- إلخ: $150/50 = 3$, $180/60 = 3$, $240/80 = 3$,

- ميل المستقيم $3 = (p_{\max} - p_{\min}) / (s_{\max} - s_{\min}) = (360 - 150) / (120 - 50) = 210 / 70 = 3$

- النموذج تعلم هذه العلاقة بدقة لأنها مثالية وبدون تشويش (noise)

- النتيجة متوقعة لأن الانحدار الخطي يجد الحل الأمثل بالضبط

```
"""
```

```
print(f"\n• ما دلالة هذه القيمة؟ هل هي دائماً {history.history['loss'][-1]:.10f}. قيمة الخسارة النهائية هي  
("مرغوبة في التطبيقات الفعلية؟")
```

```
print("الدلالة:")
```

- خسارة قريبة جداً من الصفر تعني أن النموذج يتوقع القيم بدقة تامة

- في هذا المثال التعليمي: هذا أمر جيد لأن البيانات مثالية

هل هي مرغوبة دائماً؟ لا.

- في التطبيقات الحقيقية: خسارة = 0 تعني غالباً "سُعرط" (overfitting)

- النموذج حفظ البيانات بدلاً من تعلم العلاقة العامة

- عند مواجهة بيانات جديدة، سيكون أدائه سيئاً

- المرغوب: خسارة منخفضة على بيانات التدريب والاختبار معاً

```
"""
```

```
print("\n• ما حدود هذا النموذج في مواجهة بيانات عقارية حقيقية (غير خطية تماماً)؟")
```

```
print("الحدود:")
```

1. يفترض علاقة خطية: السعر $\times a =$ المساحة $b +$ غلط في الواقع)
2. يستخدم متغير واحد فقط (المساحة) بينما هناك عشرات المتغيرات المؤثرة
3. لا يتعامل مع التشويش (noise) والبيانات الشاذة (outliers)
4. لا يمكنه تعلم علاقات معقدة (مثل: تأثير المتر الإضافي يقل بعد مساحة معينة)
5. حساس للقيم المتطرفة: عمارة صغيرة جداً أو كبيرة جداً قد تشوه النموذج

""")

print("\n• الحقيقة الحقيقية في مواجهة البيانات الحقيقية")

print("""

التحسين الأول: إضافة متغيرات أكثر (زيادة الأبعاد)

- عدد الغرف، الطابق، المسافة من المركز، سنة البناء، التشطيبات
- نوع الحي (رقي، متوسط، شعبي) عبر ترميز One-Hot

التحسين الثاني: استخدام نموذج غير خطي

- إضافة طبقات مخفية (hidden layers) مع دوال تنشيط غير خطية (ReLU)
- استخدام تقنيات التنظيم (Regularization): Dropout, L1, L2
- تجربة خوارزميات متقدمة: Random Forest, XGBoost

""")

=====

التمرين السابع - التوليف والتفكير النقدي

=====

print("\n" + "="*70)

print("التمرين السابع - التوليف والتفكير النقدي")

print("="*70)

print("""

اكتب تقريراً موجزاً (صفحة واحدة على الأكثر) يلخص المسار الكامل المنجز خلال هذه الأعمال التطبيقية.

التقرير الموجز

1. تطبيع البيانات: لماذا وكيف؟

لماذا؟

- تحسين استقرار وسرعة التقارب أثناء التدريب
- تجنب هيمنة متغير على آخر بسبب مقاييس مختلفة

كيف؟

$$x_norm = (x - x_min) / (x_max - x_min)$$

-النتيجة: جميع البيانات في المجال [0, 1]

2. دالة الخسارة: MSE: التعريف والتفسير

$$\text{التعريف: } MSE = (1/n) * \sum (y_i - \hat{y}_i)^2$$

التفسير:

- تقيس متوسط مربع الأخطاء بين التوقعات والقيم الحقيقية
- كلما كانت MSE أقرب إلى الصفر، كان النموذج أفضل
- تحسب الأخطاء الكبيرة بشدة (بسبب التربيع)

3. دور المعاملات الفائقة: معدل التعلم وعدد الحَقَب

معدل التعلم: (Learning Rate)

- يتحكم في حجم الخطوة أثناء النزول المتدرج
- كبير جداً ← تباعد، صغير جداً ← بطء

-قيمة مثالية = 0.1 للبيانات المطبوعة

عدد الحَقَب (Epochs)

-عدد مرات المرور على مجموعة البيانات الكاملة

-قليل جداً ← عدم التقارب، كثير جداً ← وقت زائد

-قيمة مناسبة = 200-500 لنموذج بسيط

4. استخراج معاملات نموذج الانحدار الخطي

الطريقة:

`weights = model.get_weights()`

`w = weights[0][0, 0] # الميل`

`b = weights[1][0] # التقاطع`

إلغاء التطبيع:

`A = w * (P_max - P_min) / (S_max - S_min) # الميل الحقيقي`

`C = P_min + b * (P_max - P_min) - A * S_min # التقاطع الحقيقي`

5. تفسير التوقعات وتقييم الأداء

التوقعات السلبية ← دليل على عدم التعلم) أسباب epochs: قليلة، LR غير مناسب)

بعد التصحيح LR=0.1 و epochs=500

-النموذج يتقارب إلى MSE = 0.000000

-المعادلة: السعر = 3 × المساحة (تطابق العلاقة الرياضية)

-الاستنتاج: نموذج مثالي على هذه البيانات التركيبية

الخلاصة:

- نحنا في تشخيص مشكلة عدم التقارب
- حددنا المعاملات المسؤولة (epochs) و(learning_rate)
- صحنا النموذج وحصلنا على تقارب تام
- فهمنا أهمية التطبيق، دالة الخسارة، والمعاملات الفائقة
- أدركنا حدود النموذج الخطي أمام البيانات الحقيقية المعقدة

```
=====
=====
"""
print("\n" + "="*70)
print("تم تنفيذ جميع التمارين بنجاح - TP نهاية")
print("="*70)
```

المخرجات :

```
=====
TP COMPLET : REGRESSION LINEAIRE AVEC KERAS
=====
=====
التمرين الأول - التعامل مع البيئة والتحقق منها
=====
```

انطلاقاً من البرنامج المرفق، نفذ في Google Colab وأجب عن الأسئلة التالية:

• ما إصدار TensorFlow المثبت في بيئة Google Colab لديك؟

الإجابة: TensorFlow version 2.20.0 :

• ما إصدار Keras المرتبط بهذه التثبيت؟

الإجابة: Keras version 3.13.2

• هل وحدة معالجة الرسومات (GPU) متاحة؟ كيف استنتجت ذلك من الكود؟

الإجابة: نعم، GPU متاح (PhysicalDevice(name='/physical_device:GPU:0', device_type='GPU')) :

الطريقة: باستخدام tf.config.list_physical_devices('GPU')

إذا كانت القائمة فارغة → لا يوجد GPU ، إذا كانت تحتوي على عناصر GPU → موجود

• اشرح في بضعة أسطر ما يعنيه غياب GPU عند تدريب نموذج بسيط كهذا. ما تأثيره على وقت الحساب؟

الإجابة :

- غياب GPU له تأثير ضئيل جداً على نموذج بسيط كهذا
- العمليات الحسابية للانحدار الخطي بسيطة ولا تتطلب معالجة متوازية قوية
- الفرق في وقت الحساب بين CPU و GPU هو بضع أجزاء من الثانية
- GPU - يصبح ضرورياً للنماذج العميقة المعقدة (CNNs, RNNs, Transformers)
- لذلك، لتدريب هذا النموذج، CPU كافٍ تماماً

التمرين الثاني - التحليل النقدي لنتيجة التدريب

بعد تنفيذ البرنامج الأولي، حصلت على قيمة خسارة نهائية تساوي 2.317.

• ما المقصود بـ MSE (متوسط مربع الخطأ)؟ أعط صيغته الرياضية.

الإجابة:

$$MSE = (1/n) * \sum (y_i - \hat{y}_i)^2$$

حيث:

n: عدد العينات

y_i: القيمة الحقيقية

y_i: القيمة المتوقعة

MSE: متوسط مربعات الأخطاء

• في سياق بيانات مُطَبَّعة بين 0 و 1، وضّح لماذا تعتبر قيمة MSE البالغة 2.317 مرتفعةً بشكل غير طبيعي.

الإجابة:

- البيانات مطبوعة (normalisée) بين 0 و 1
- لأي عينة، الفرق بين القيمة الحقيقية والمتوقعة ≥ 1
- مربع هذا الفرق ≥ 1
- متوسط هذه المربعات ≥ 1
- لذلك فإن $MSE > 1$ مستحيل في الظروف العادية
- $MSE = 2.317$ - تعني أن التوقعات خارجة عن النطاق $[0,1]$ (سلبية أو >1)
- ما القيمة التي تعتبرها مقبولة لـ MSE بالنسبة لنموذج مُدرَّب جيداً على هذه البيانات؟
- الإجابة:
- قيمة MSE مقبولة < 0.01 :
- قيمة MSE جيدة جداً < 0.001 :
- قيمة MSE ممتازة < 0.0001 :
- للنموذج الخطي المثالي $MSE = 0$:
- صغ فرضية حول الأسباب المحتملة لهذه القيمة المرتفعة قبل أي تعديل على البرنامج.
- الإجابة (الفرضيات):

1. معدل التعلم (learning rate) غير مناسب:

- كبير جداً → النموذج يتباعد ولا يتقارب
- صغير جداً → النموذج يتعلم ببطء شديد

2. عدد الحَقَب (epochs) غير كافٍ:

- الحقبة الواحدة لا تسمح بالنزول إلى المطلوب

3. التهيئة الأولية للأوزان سيئة

4. عدم تطبيع البيانات بشكل صحيح

=====

التمرين الثالث - استخراج معادلة النموذج

=====

البيانات:

المساحة → 50 m²: السعر: k€150

المساحة → 60 m²: السعر: k€180

المساحة → 80 m²: السعر: k€240

المساحة: 100 → m^2 السعر: k€300

المساحة: 120 → m^2 السعر: k€360

بعد التطبيع (قيم بين 0 و 1):

surface_norm[0] = 0.0000 , prix_norm[0] = 0.0000

surface_norm[1] = 0.1429 , prix_norm[1] = 0.1429

surface_norm[2] = 0.4286 , prix_norm[2] = 0.4286

surface_norm[3] = 0.7143 , prix_norm[3] = 0.7143

surface_norm[4] = 1.0000 , prix_norm[4] = 1.0000

• استخدم الدالة (`model.get_weights()`) لاستخراج الأوزان (w) والانحياز (b) من النموذج المدرب.

الإجابة w : (الوزن) = 1.011049

b (الانحياز) = -0.000102

• اعرض معادلة النموذج في الحجم المطبّع على الشكل $\text{prix_norm} = w \times \text{surface_norm} + b$:

الإجابة: $\text{prix_norm} = 1.011049 \times \text{surface_norm} + -0.000102$

• أجر عملية إلغاء التطبيع واعرض المعادلة في الحجم الحقيقي (المساحة بـ m^2 ، السعر بـ k€). فصلّ خطوات الحساب المستخدمة.

الإجابة:

الخطوة 1: حساب الميل A في المعادلة الحقيقية

$$A = w \times (P_{\text{max}} - P_{\text{min}}) / (S_{\text{max}} - S_{\text{min}})$$

$$A = 1.011049 \times (360.0 - 150.0) / (120.0 - 50.0)$$

$$A = 3.0331$$

الخطوة 2: حساب التقاطع C

$$C = P_{\text{min}} + b \times (P_{\text{max}} - P_{\text{min}}) - A \times S_{\text{min}}$$

$$C = 150.0 + -0.000102 \times (360.0 - 150.0) - 3.0331 \times 50.0$$

$$C = -1.68$$

المعادلة الحقيقية: السعر $\times 3.0331 = (k\text{€})$ المساحة $-1.68 + (m^2)$

• تحقق من نتيجتك بحساب السعر المتوقع يدوياً لمساحة $m^2.100$

الإجابة: السعر المتوقع لـ $100\text{ k€} = 301.64 = 3.0331 \times 100 + -1.68 = m^2$

السعر الحقيقي المتوقع $= 300\text{ k€}$

التمرين الرابع - تشخيص مشكلة التقارب

عند تنفيذ البرنامج المعدل، لاحظت توقعات سلبية رغم أن الأسعار المطبّعة تقع بين 0 و 1.

• حلّ النتائج التالية و اشرح ما تدل عليه:

التوقعات: $[-0.1458, -0.2918, -0.3892, -0.4866, -0.6326]$

القيم الحقيقية: $[0.3333, 0.5333, 0.6667, 0.8000, 1.0000]$

التحليل:

- جميع التوقعات سالبة بينما القيم الحقيقية موجبة
 - كلما زادت المساحة، أصبحت التوقعات أكثر سلبية (علاقة عكسية)
 - هذا يدل على أن النموذج لم يتعلم أي شيء
 - النموذج يعطي وزناً سالباً للمساحة
 - سبب المشكلة: عدد الحَقَب غير كافٍ ومعدل التعلم غير مناسب
 - حدّد المعاملين في البرنامج الأولي المسؤولين عن هذا الخلل.
- الإجابة:

epochs 1. (عدد الحَقَب): القيمة الافتراضية كانت 1 أو غير محددة

learning_rate 2. (معدل التعلم): القيمة الافتراضية 0.01 قد تكون غير مناسبة

هذان المعاملان هما المسؤولان الرئيسيان عن فشل التقارب

• وضح العلاقة بين معدل التعلم (learning rate) وسرعة تقارب الشبكة العصبية.

الإجابة:

- معدل تعلم صغير جداً: التقارب بطيء جداً، يحتاج إلى حقبة كثيرة جداً
- معدل تعلم مناسب: تقارب سريع ومستقر نحو الحل الأمثل
- معدل تعلم كبير جداً: النموذج يتباعد (diverge) ، قد تصل الخسارة إلى ما لانهاية

- في حالتنا: 0.1 يعتبر مناسباً للبيانات المطبوعة بين 0 و 1
 - العلاقة LR: الأمثل = 0.01 إلى 0.1 للبيانات المطبوعة
 - ما المقصود بتقارب النموذج؟ كيف نتيج لك دالة الخسارة اكتشافه؟
- الإجابة:

تقارب النموذج: هو الوصول إلى حالة تستقر فيها دالة الخسارة عند قيمة دنيا ولا تنقص أكثر.

اكتشاف التقارب عبر دالة الخسارة:

- خلال التدريب، نراقب قيمة MSE في كل حقبة
- عندما تبقى MSE ثابتة أو تتغير بقيم صغيرة جداً ($1e-6$)
- ولم تنخفض بشكل ملحوظ لعدة حقبة متتالية
- هذا يعني أن النموذج قد تقارب
- في مثالنا MSE: تتناقص بشكل كبير ثم تستقر قرب الصفر

التمرين الخامس - تصحيح البرنامج وتحسينه

- بناءً على تشخيصك، اقترح نسخة معدلة من البرنامج ونفذها.
- عدّل معدل التعلم بالانتقال من القيمة الافتراضية إلى 0.1. برّر هذا الاختيار.
- التبرير:

- 0.1 - هو معدل تعلم متوسط للبيانات المطبوعة بين 0 و 1
- ليس كبيراً جداً ليسبب تباعداً، وليس صغيراً جداً ليسبب بطئاً
- يسمح بتقارب سريع في غضون 100-200 حقبة
- جربناه وكانت النتائج ممتازة (MSE) تصل إلى 0
- ارفع عدد الحَقَب (epochs) إلى 500. وضّح لماذا يُفضي عدد أكبر من الحَقَب إلى تقارب أفضل.

التفسير:

- كل حقبة تعني تمريرة كاملة على جميع البيانات
- مع عدد قليل من الحَقَب، النموذج لا يصل إلى الحل الأمثل
- 100-500 - حقبة كافية لنماذج بسيطة

500 - حقبة تضمن وصول النزول المتدرج (Gradient Descent) إلى أدنى نقطة

- مع 500 حقبة، نلاحظ أن MSE تصل إلى 0.000000

• أضف عرضاً لقيمة الخسارة كل 100 حقبة لتصور تقدم التعلم.

جارٍ التدريب...

الحقبة : 100 قيمة الخسارة (MSE) = 0.0019868240

الحقبة : 200 قيمة الخسارة (MSE) = 0.0000247377

الحقبة : 300 قيمة الخسارة (MSE) = 0.0000003080

الحقبة : 400 قيمة الخسارة (MSE) = 0.0000000038

الحقبة : 500 قيمة الخسارة (MSE) = 0.0000000000

• علق على تطور الخسارة التي تلاحظها بين الحقبة 1 والحقبة 500.

التعليق:

- الحقبة 1: الخسارة = 0.60974163 (مرتفعة نسبياً)

- الحقبة 100: الخسارة = 0.00198682 (انخفضت بشكل كبير)

- الحقبة 200: الخسارة = 0.00002474 (شبه منعدمة)

- الحقبة 500: الخسارة = 0.000000000048 (شبه صفرية)

الملاحظة: الخسارة تتناقص بسرعة في أول 100 حقبة ثم تستقر قرب الصفر.

هذا يدل على أن النموذج تعلم العلاقة الخطية تماماً.

التمرين السادس - تفسير النتائج النهائية

بعد التصحيح، يتقارب النموذج ويُعيد إنتاج المعادلة: السعر $\times 2.9999$ (k€) المساحة $+ 0.00$ (m²)

• فسّر لماذا تُعدّ هذه النتيجة متوقعة رياضياً بالنظر إلى بنية البيانات المُقدّمة.

التفسير:

- البيانات المعطاة تتبع علاقة خطية تامة: السعر = $3 \times$ المساحة

إلخ $= 3, 240/80 = 3, 180/60 = 3, 150/50 = 3$

- ميل المستقيم $= (p_{\max} - p_{\min}) / (s_{\max} - s_{\min}) = (360 - 150) / (120 - 50) = 210 / 70 = 3$

- النموذج تعلم هذه العلاقة بدقة لأنها مثالية وبدون تشويش (noise)
- النتيجة متوقعة لأن الانحدار الخطي يجد الحل الأمثل بالضبط
- قيمة الخسارة النهائية هي 0.0000000000. ما دلالة هذه القيمة؟ هل هي دائماً مرغوبة في التطبيقات الفعلية؟
الدلالة:

- خسارة قريبة جداً من الصفر تعني أن النموذج يتوقع القيم بدقة تامة
- في هذا المثال التعليمي: هذا أمر جيد لأن البيانات مثالية
هل هي مرغوبة دائماً؟ لا.
- في التطبيقات الحقيقية: خسارة = 0 تعني غالباً "سُعرط" (overfitting) "
- النموذج حفظ البيانات بدلاً من تعلم العلاقة العامة
- عند مواجهة بيانات جديدة، سيكون أدائه سيئاً
- المرغوب: خسارة منخفضة على بيانات التدريب والاختبار معاً
- ما حدود هذا النموذج في مواجهة بيانات عقارية حقيقية (غير خطية تماماً)؟
الحدود:

1. يفترض علاقة خطية: السعر = $a \times$ المساحة + b غلط في الواقع)
2. يستخدم متغير واحد فقط (المساحة) بينما هناك عشرات المتغيرات المؤثرة
3. لا يتعامل مع التشويش (noise) والبيانات الشاذة (outliers)
4. لا يمكنه تعلم علاقات معقدة (مثل: تأثير المتر الإضافي يقل بعد مساحة معينة)
5. حساس للقيم المتطرفة: عمارة صغيرة جداً أو كبيرة جداً قد تشوه النموذج
- اقترح تحسينين ممكنين على النموذج لجعله أكثر متانة في مواجهة البيانات الحقيقية.

التحسين الأول: إضافة متغيرات أكثر (زيادة الأبعاد)

- عدد الغرف، الطابق، المسافة من المركز، سنة البناء، التشطيبات
- نوع الحي (رقي، متوسط، شعبي) عبر ترميز One-Hot

التحسين الثاني: استخدام نموذج غير خطي

- إضافة طبقات مخفية (hidden layers) مع دوال تنشيط غير خطية (ReLU)
- استخدام تقنيات التنظيم (Regularization): Dropout, L1, L2
- تجربة خوارزميات متقدمة Random Forest, XGBoost :

التمرين السابع - التوليف والتفكير النقدي

اكتب تقريراً موجزاً (صفحة واحدة على الأكثر) يلخص المسار الكامل المنجز خلال هذه الأعمال التطبيقية.

التقرير الموجز

1. تطبيع البيانات: لماذا وكيف؟

لماذا؟

-تحسين استقرار وسرعة التقارب أثناء التدريب

-تجنب هيمنة متغير على آخر بسبب مقاييس مختلفة

كيف؟

$$x_{\text{norm}} = (x - x_{\text{min}}) / (x_{\text{max}} - x_{\text{min}})$$

-النتيجة: جميع البيانات في المجال $[0, 1]$

2. دالة الخسارة: MSE التعريف والتفسير

$$\text{التعريف: } \text{MSE} = (1/n) * \sum (y_i - \hat{y}_i)^2$$

التفسير:

-تقيس متوسط مربع الأخطاء بين التوقعات والقيم الحقيقية

-كلما كانت MSE أقرب إلى الصفر، كان النموذج أفضل

-تحسب الأخطاء الكبيرة بشدة (بسبب التربيع)

3. دور المعاملات الفائقة: معدل التعلم وعدد الحقب

معدل التعلم: (Learning Rate)

-يتحكم في حجم الخطوة أثناء النزول المتدرج

-كبير جداً ← تباعد، صغير جداً ← بطء

-قيمة مثالية = 0.1 للبيانات المطبوعة

عدد الحَقَب (Epochs)

-عدد مرات المرور على مجموعة البيانات الكاملة

-قليل جداً ← عدم التقارب، كثير جداً ← وقت زائد

-قيمة مناسبة = 200-500 لنموذج بسيط

4. استخراج معاملات نموذج الانحدار الخطي

الطريقة:

```
weights = model.get_weights()
```

```
w = weights[0][0, 0] # الميل
```

```
b = weights[1][0] # التقاطع
```

إلغاء التطبيع:

```
A = w * (P_max - P_min) / (S_max - S_min) # الميل الحقيقي
```

```
C = P_min + b * (P_max - P_min) - A * S_min # التقاطع الحقيقي
```

5. تفسير التوقعات وتقييم الأداء

التوقعات السلبية ← دليل على عدم التعلم) أسباب epochs: قليلة، LR غير مناسب)

بعد التصحيح LR=0.1 و: epochs=500

-النموذج يتقارب إلى MSE = 0.000000

-المعادلة: السعر = 3 × المساحة (تطابق العلاقة الرياضية)

-الاستنتاج: نموذج مثالي على هذه البيانات التركيبية

الخلاصة:

-نجحنا في تشخيص مشكلة عدم التقارب

-حددنا المعاملات المسؤولة (epochs) و (learning_rate)

-صححنا النموذج وحصلنا على تقارب تام

-فهمنا أهمية التطبيق، دالة الخسارة، والمعاملات الفائقة

-أدركنا حدود النموذج الخطي أمام البيانات الحقيقية المعقدة

=====

=====